



Universidade do Minho
Escola de Engenharia

Aprendizagem e Decisão Inteligentes

Trabalho Prático

Grupo 23

10/05/2026

Ano Letivo 2025/2026

Samuel Gibson da Cunha Figueiredo Lobato — A106907

Afonso Dinis Cerqueira Carpinteiro — A106909

Afonso Miguel Carvalho de Jesus Quartas — A106880

Bruno Daniel Lima Carvalho — A106809

Resumo

O trabalho desenvolvido na unidade curricular de Aprendizagem e Decisão Inteligentes aplicou diferentes técnicas de machine learning e utilizou diferentes paradigmas de aprendizagem para resolver problemas reais. Foram exploradas duas tarefas com datasets distintos, que foram analisados e modelados através da plataforma KNIME. O processo envolveu a preparação dos dados, a construção de modelos preditivos de classificação e regressão, e a avaliação dos resultados com métricas adequadas. O relatório documenta todas as fases do trabalho, evidenciando o potencial e os desafios da aplicação de métodos de machine learning aos domínios do consumo de energia elétrica a nível nacional, e a nível doméstico, em França.

1. Introdução

O presente relatório descreve o trabalho prático realizado no âmbito da unidade curricular de Aprendizagem e Decisão Inteligentes, da Licenciatura em Engenharia Informática da Universidade do Minho, no ano letivo 2025/2026. O trabalho é constituído por duas tarefas complementares: a primeira incide sobre um dataset atribuído pela equipa docente, relativo ao consumo de energia elétrica em nível nacional; a segunda corresponde a um dataset escolhido pelo grupo, intitulado «Individual Household Electric Power Consumption», que diz respeito ao consumo de energia elétrica de uma habitação individual em Sceaux, França. Ambas as tarefas foram desenvolvidas integralmente na plataforma KNIME Analytics Platform.

Optou-se por trabalhar com dois conjuntos de dados centrados na mesma temática — o consumo de energia elétrica — mas em escalas distintas (macroscópica e microscópica), permitindo explorar perspetivas e abordagens de modelação variadas sobre um domínio comum. Esta escolha enriquece a análise comparativa e evidencia como diferentes granularidades de dados influenciam o desenho dos modelos de aprendizagem automática.

Ao longo do documento são descritas as metodologias seguidas, as decisões tomadas em cada fase do processo, os resultados obtidos e a respetiva análise crítica. Pretende-se demonstrar a capacidade do grupo de aplicar os conhecimentos teóricos adquiridos em cenários reais, bem como avaliar de forma fundamentada o desempenho das soluções baseadas em machine learning desenvolvidas, contribuindo para o desenvolvimento de competências práticas na área da ciência de dados e da inteligência artificial.

2. Metodologia

Para estruturar o desenvolvimento do trabalho foi adotada a metodologia CRISP-DM (Cross-Industry Standard Process for Data Mining), que se revelou particularmente adequada por organizar o processo de descoberta de conhecimento em fases claras e iterativas: compreensão do negócio, compreensão dos dados, preparação dos dados, modelação,

avaliação e implementação. A natureza modular do CRISP-DM facilita a consistência metodológica entre projetos com objetivos diferentes, como é o caso, permitindo manter uma estrutura coerente ao longo de todo o trabalho.

O trabalho foi desenvolvido com dois conjuntos de dados em paralelo: um dataset de classificação multiclasse, fornecido pelos docentes, com o objetivo de prever a categoria de consumo energético em nível nacional; e um dataset escolhido pelo grupo, com objetivos múltiplos — classificação do nível de consumo doméstico, regressão sobre a potência ativa global e clustering para identificação de padrões intrínsecos de consumo. Apesar de se tratarem de problemas distintos, a mesma estrutura metodológica foi mantida para ambos os datasets, pois o CRISP-DM oferece a flexibilidade necessária para tratar diferentes tipos de problemas de forma sistemática e coerente.

O relatório encontra-se estruturado em duas grandes secções, correspondentes a cada uma das tarefas, ambas organizadas internamente pelas fases do CRISP-DM. Esta abordagem permite uma descrição clara e sequencial do trabalho desenvolvido em cada etapa, facilitando a leitura e a reprodução dos passos realizados.

3. Dataset Atribuído — Consumo de Energia Elétrica

Nas subsecções seguintes apresenta-se em detalhe o trabalho desenvolvido sobre o dataset atribuído ao Grupo 23, seguindo as fases da metodologia CRISP-DM.

1. Estudo de Negócio

O dataset atribuído ao grupo é relativo ao consumo de energia elétrica em nível nacional, englobando dados de consumo por nível de tensão e variáveis meteorológicas associadas.

O contexto energético nacional apresenta desafios significativos no que diz respeito à previsão e gestão da procura elétrica. A capacidade de classificar corretamente o nível de consumo com base em condições meteorológicas e padrões temporais reveste-se de grande importância para operadores de rede, comercializadores de energia e entidades reguladoras. Uma classificação precisa permite otimizar a gestão da rede, planear a produção energética e implementar políticas tarifárias mais eficientes.

O objetivo específico deste projeto consiste em desenvolver um modelo preditivo capaz de classificar o consumo energético em cinco categorias distintas: "Low Consumption", "Medium-Low Consumption", "Medium Consumption", "Medium-High Consumption" e "High Consumption". Para tal, são utilizadas variáveis de entrada que incluem os consumos parciais por nível de tensão (Muito Alta, Alta, Média e Baixa Tensão), variáveis meteorológicas (temperatura, humidade relativa, precipitação, radiação solar, velocidade do vento, entre outras) e informação temporal (hora, dia, mês).

A metodologia adotada segue o modelo CRISP-DM (Cross-Industry Standard Process for Data Mining), que estrutura o processo de descoberta de conhecimento em seis fases: compreensão do negócio, compreensão dos dados, preparação dos dados, modelação, avaliação e implementação. O workflow foi integralmente desenvolvido na plataforma KNIME Analytics Platform, que permite a construção visual de pipelines de dados e a integração de diversos algoritmos de aprendizagem automática.

A estrutura do workflow é composta por três blocos principais: (1) "Load Data", responsável pela leitura do ficheiro CSV; (2) "Data Visualization-Treatment-Exploration", um componente que engloba toda a visualização, tratamento e exploração dos dados; e (3) "Model Training", que contém todos os modelos de classificação, regressão e clustering implementados.

2. Análise dos Dados

2.1. Análise do Dataset

O dataset original, denominado "consumption_dataset.csv", é composto por 8736 registos e 24 atributos. Cada registo corresponde a uma observação horária do consumo energético, acompanhada de variáveis meteorológicas recolhidas para o mesmo período temporal. A variável alvo é "Consumptions", uma variável categórica que classifica o nível de consumo total. O período temporal abrangido pelo dataset estende-se de 2024 a 2026.

A tabela seguinte apresenta os atributos do dataset, os seus tipos de dados originais e uma breve descrição do seu significado:

Atributo	Tipo	Descrição
Date/Time	String	Data e hora da observação (YYYY-MM-DD HH:MM)
Very High Voltage (kWh)	Float	Consumo em Muito Alta Tensão
High Voltage (kWh)	Float	Consumo em Alta Tensão
Medium Voltage (kWh)	String*	Consumo em Média Tensão
Low Voltage (kWh)	Float	Consumo em Baixa Tensão
Total (kWh)	String*	Consumo total (soma das tensões)
temperature_2m (°C)	Float	Temperatura a 2 metros do solo
relative_humidity_2m (%)	Float	Humidade relativa a 2 metros
apparent_temperature (°C)	Float	Temperatura aparente (sensação térmica)
precipitation (mm)	Float	Precipitação acumulada
rain (mm)	Float	Chuva acumulada
snowfall (cm)	Float	Queda de neve (constante = 0)
cloud_cover (%)	Float	Cobertura de nuvens
wind_speed_10m (km/h)	Float	Velocidade do vento a 10 metros
Diffuse_Radiation	String	Radiação difusa (categórica)
Direct_Radiation	String	Radiação direta (categórica)
Consumptions	String	Classe de consumo (variável alvo)

* Nota: As colunas "Medium Voltage (kWh)" e "Total (kWh)" foram importadas como String devido à presença de valores "nan" em formato de texto, necessitando de conversão posterior.

(ver Anexo 1 — Figura 1: Tipos de dados das colunas do dataset original, conforme identificados pelo KNIME.)

A análise inicial revelou que o dataset contém variáveis numéricas contínuas (consumos e variáveis meteorológicas), variáveis categóricas (Diffuse_Radiation, Direct_Radiation e Consumptions) e uma variável temporal (Date/Time). A coluna "snowfall" apresenta variância

zero, sendo constante em todo o dataset (valor sempre igual a 0), o que a torna irrelevante para a modelação.

Através do nó "Data Explorer" do KNIME, obtiveram-se as estatísticas descritivas completas para todas as variáveis numéricas, incluindo média, mediana, desvio padrão, valores mínimos e máximos. A figura seguinte apresenta um resumo destas estatísticas.

(ver Anexo 2 — Figura 2: Estatísticas descritivas geradas pelo nó Data Explorer do KNIME.)

A distribuição da variável alvo "Consumptions" apresentou um ligeiro desbalanceamento entre as classes. Após a normalização dos nomes das classes (descrita na secção de preparação), a distribuição final é a seguinte: "Medium-High Consumption" com 2180 registos (24.96%), "Medium Consumption" com 2090 registos (23.94%), "Low Consumption" com 1998 registos (22.88%), "Medium-Low Consumption" com 1674 registos (19.17%) e "High Consumption" com 790 registos (9.05%). O desbalanceamento é particularmente notório na classe "High Consumption", que possui menos de metade dos registos das classes mais representadas.

(ver Anexo 3 — Figura 3: Distribuição de ocorrências por classe de consumo após normalização.)

A análise dos valores máximos e mínimos de consumo total para cada classe revelou inconsistências na classificação original. Observou-se que a classe "Medium Consumption" apresenta um valor máximo de Total (1 879 953.60 kWh) superior ao máximo da classe "Medium-High Consumption" (1 850 911.75 kWh), e que a classe "Medium-Low Consumption" apresenta igualmente um máximo (1 903 633.90 kWh) superior ao da classe "Medium-High". Esta sobreposição sugere que a classificação original não foi baseada exclusivamente no valor do consumo total, mas possivelmente em critérios multidimensionais.

(ver Anexo 4 — Figura 4: Valores máximos e mínimos de consumo total para cada classe de classificação.)

A análise da correlação linear entre as variáveis numéricas revelou padrões importantes. Existe uma forte correlação positiva entre os diferentes níveis de tensão e o consumo total, o que é expectável dado que o total é a soma das parcelas. Observou-se igualmente uma correlação elevada entre "temperature_2m" e "apparent_temperature", bem como uma correlação perfeita entre "precipitation" e "rain", confirmando a redundância destas variáveis.

(ver Anexo 5 — Figura 5: Matriz de correlação linear entre as variáveis numéricas do dataset.)

O box plot da variável "Total (kWh)" permitiu identificar a presença de outliers significativos nos valores mais baixos de consumo. A mediana situa-se aproximadamente em 1.48 milhões de kWh, com o intervalo interquartil entre 1.28 e 1.70 milhões de kWh. Foram identificados outliers abaixo dos 600 000 kWh, com valores extremos próximos de 20 000 kWh, que correspondem provavelmente a períodos de manutenção ou falhas no registo.

(ver Anexo 6 — Figura 6: Box plot da variável Total (kWh), evidenciando outliers nos valores baixos.)

A análise dos padrões temporais de consumo revelou informações valiosas sobre o comportamento energético. O gráfico de consumo horário por dia da semana demonstra que os dias úteis (segunda a sexta-feira) apresentam um padrão muito semelhante entre si, com dois picos: um pela manhã (entre as 9h e as 12h) e outro mais pronunciado ao final da tarde/noite (pico às 20h, atingindo aproximadamente 1.85 milhões de kWh). O fim de semana apresenta um comportamento distinto, com o sábado ligeiramente abaixo dos dias úteis e o domingo com consumos significativamente inferiores (pico de apenas ~1.65 milhões de kWh). O mínimo de consumo ocorre consistentemente por volta das 5h da manhã em todos os dias da semana.

(ver Anexo 7 — Figura 7: Consumo horário médio por dia da semana.)

O mapa de calor (heatmap) do consumo médio total por mês e hora do dia evidenciou a forte sazonalidade do consumo energético. Os meses de inverno (janeiro, novembro e dezembro) registam os maiores níveis de consumo, especialmente no período noturno entre as 17h e as 20h (representados em tons de laranja/vermelho, com valores acima de 2.1 milhões de kWh). Em contraste, os meses de primavera e início de verão (abril, maio, junho) apresentam os consumos mais baixos, particularmente durante a madrugada (representados em tons de roxo escuro, com valores próximos de 1.1 milhões de kWh).

(ver Anexo 8 — Figura 8: Mapa de calor do consumo médio total por mês e hora do dia.)

A análise sazonal confirmou que o inverno é a estação com maior consumo médio (aproximadamente 1.70 milhões de kWh), seguido do outono (~1.55 milhões), verão (~1.42 milhões) e primavera (~1.32 milhões de kWh). Esta sazonalidade está diretamente relacionada com a necessidade de aquecimento nos meses mais frios e com a redução das horas de luz natural, que aumenta a utilização de iluminação artificial.

(ver Anexo 9 — Figura 9: Consumo médio total por estação do ano.)

A distribuição do consumo pelos diferentes períodos do dia (obtida através de binning da variável hora em quatro intervalos) revelou que a noite é o período com maior consumo médio (~1.73 milhões de kWh), seguida da tarde (~1.62 milhões), manhã (~1.50 milhões) e madrugada (~1.22 milhões de kWh). Este padrão reflete a concentração das atividades domésticas e industriais nos períodos diurnos e do início da noite.

(ver Anexo 10 — Figura 10: Consumo médio total por período do dia (Madrugada, Manhã, Tarde, Noite).)

A análise do consumo por nível de tensão e classe demonstrou que a Baixa Tensão (Low Voltage) é consistentemente o maior contribuinte para o consumo total em todas as classes de classificação, representando a maior parcela do consumo. A Muito Alta Tensão (Very High Voltage) apresenta a menor contribuição relativa. Esta distribuição é coerente com a realidade do sistema elétrico português, onde a maioria dos consumidores (residenciais e pequenos comerciais) está ligada à rede de baixa tensão.

(ver Anexo 11 — Figura 11: Consumo médio por nível de tensão e classe de consumo.)

A distribuição das classes por mês revelou padrões sazonais na classificação do consumo, com maior prevalência de classes de consumo elevado nos meses de inverno e de classes de consumo baixo nos meses de verão, confirmando a relação entre sazonalidade e nível de consumo.

(ver Anexo 12 — Figura 12: Distribuição das classes de consumo por mês.)

2.2. Conclusão sobre o Dataset

A análise exploratória permitiu identificar diversas características e problemas no dataset que necessitam de tratamento antes da fase de modelação. De seguida, enumeram-se os principais problemas identificados e as respetivas implicações para o pré-processamento.

Em primeiro lugar, detetaram-se tipos de dados incorretos: as colunas "Medium Voltage (kWh)" e "Total (kWh)" estão armazenadas como String devido à presença de valores "nan" em formato de texto, necessitando de conversão para formato numérico. Em segundo lugar, foram identificados 7 registos com datas impossíveis (dia 32, mês 13, 30 de fevereiro), que devem ser removidos do dataset.

(ver Anexo 13 — Figura 13: Registos identificados com datas inválidas no dataset.)

Em terceiro lugar, verificou-se uma redundância total entre as colunas "precipitation (mm)" e "rain (mm)", que são idênticas em todos os registos não-nulos, constituindo uma duplicação desnecessária. Em quarto lugar, a coluna "snowfall" apresenta variância zero, não contribuindo com informação discriminativa para a modelação.

(ver Anexo 14 — Figura 14: Demonstração da igualdade entre as colunas precipitation e rain.)

Em quinto lugar, a coluna "Consumptions" contém múltiplas representações para a mesma classe (por exemplo, "Hgh" e "High Consumption", "MedHgh" e "Medium-High Consumption"), necessitando de normalização. Em sexto lugar, existem registos com valores em falta nas colunas de tensão, identificados pela verificação da consistência da soma (723 registos com soma inconsistente ou valores ausentes). Finalmente, observa-se um desbalanceamento de classes, com a classe "High Consumption" a possuir significativamente menos registos (790) do que as restantes.

(ver Anexo 15 — Figura 15: Verificação da consistência da soma das tensões parciais com o total.)

3. Preparação dos Dados

3.1. Limpeza dos Dados (Pré-processamento)

A fase de pré-processamento envolveu a correção de todas as anomalias identificadas na análise exploratória. O pipeline de limpeza foi implementado no KNIME através de uma sequência estruturada de nós dentro do componente "Data Visualization-Treatment-Exploration" (Component #484).

Conversão de tipos de dados: Utilizou-se o nó "String to Number" para converter as colunas "Medium Voltage (kWh)" e "Total (kWh)" de String para formato numérico (Double). Os valores "nan" em formato de texto foram automaticamente convertidos para valores ausentes (missing values) durante este processo. Esta conversão é essencial para que os algoritmos de aprendizagem possam processar corretamente estas variáveis numéricas.

Remoção de datas inválidas: Através de um nó "String to Date/Time" seguido de "Row Filter" configurado para a coluna "ValidDate", foram removidos os 7 registos com datas impossíveis (Row726, Row1158, Row1256, Row3284, Row4641, Row6703 e Row6829). Estas datas incluíam combinações como "2025-11-32" (dia 32), "2024-02-30" (30 de fevereiro) e "2026-13-04" (mês 13), que não correspondem a datas reais no calendário.

Normalização da variável alvo: A coluna "Consumptions" foi padronizada através de um nó "Rule Engine" que mapeou todas as variantes de nomenclatura para as cinco classes canónicas. As regras de mapeamento aplicadas foram as seguintes:

Valor Original	Classe Normalizada
"Hgh"	High Consumption
"MedioAlto", "MedHgh"	Medium-High Consumption
"Med", "Medium"	Medium Consumption
"MedioBaixo", "MedLow"	Medium-Low Consumption
"Lw"	Low Consumption

Eliminação de redundância: Dado que as colunas "precipitation (mm)" e "rain (mm)" são idênticas em todos os registos não-nulos (conforme demonstrado na Figura 14), utilizou-se um nó "Column Expressions" para consolidar a informação numa única coluna, eliminando a duplicação. A lógica implementada mantém o valor de precipitação disponível (de qualquer uma das colunas) e preserva os valores ausentes quando ambas são nulas.

3.2. Construção dos Dados (Feature Engineering)

Para enriquecer o dataset com informação temporal relevante, foram extraídas novas variáveis a partir da coluna "Date/Time" utilizando nós "Column Expressions" e "Date/Time Part Extractor":

Extração temporal: Foram criadas as colunas "Year", "Month", "Day" e "Hour" a partir da data original, permitindo capturar padrões sazonais, mensais e diários no consumo energético. A extração foi realizada através de operações de substring sobre a coluna de texto e posterior conversão para formato numérico inteiro.

Binning temporal: Utilizaram-se nós "Rule Engine" para criar variáveis derivadas de agrupamento temporal. A variável "Hour [Binned]" agrupa as horas em quatro períodos do dia: Madrugada (Bin 1: 0h-5h), Manhã (Bin 2: 6h-11h), Tarde (Bin 3: 12h-17h) e Noite (Bin 4: 18h-23h). A variável "Month [Binned]" agrupa os meses em estações do ano: Inverno (Bin 1: dezembro-fevereiro), Primavera (Bin 2: março-maio), Verão (Bin 3: junho-agosto) e Outono (Bin 4: setembro-novembro).

Verificação de consistência: Foi criada uma coluna auxiliar "Full" (através de "Column Expressions") que indica se todas as colunas de tensão estão preenchidas (valor 1) ou se existem valores ausentes (valor 0). Complementarmente, a coluna "Consistent sum" classifica cada registo como "Match" (soma das tensões parciais igual ao total, com tolerância de 0.1), "Missing" (valores ausentes) ou "Mismatch" (inconsistência numérica). Esta verificação identificou 8009 registos consistentes ("Match") e 723 registos com valores em falta ("Missing").

3.3. Integração dos Dados (Codificação)

Para permitir a utilização das variáveis categóricas nos algoritmos de aprendizagem automática, foram aplicadas duas técnicas de codificação numérica, selecionadas conforme as necessidades de cada modelo:

Category to Number: As variáveis categóricas "Diffuse_Radiation", "Direct_Radiation" e "Consumptions" foram convertidas para valores numéricos ordinais através do nó "Category to Number". Esta codificação atribui um valor inteiro sequencial a cada categoria, começando em 0, e é particularmente adequada para os modelos de regressão que necessitam de uma representação numérica da variável alvo.

One to Many (One-Hot Encoding): Para os modelos que requerem variáveis binárias independentes e que não devem assumir uma relação ordinal entre categorias, aplicou-se a codificação one-hot através do nó "One to Many". Esta técnica cria uma coluna binária (0/1) para cada categoria das variáveis categóricas, eliminando qualquer pressuposição de ordenação.

3.4. Seleção de Dados

Com base na análise exploratória, foram removidas as seguintes variáveis por serem irrelevantes ou redundantes para a modelação: "snowfall" (variância zero em todo o dataset), "rain (mm)" (duplicada de "precipitation"), e "Date/Time" (substituída pelas componentes temporais extraídas Year, Month, Day e Hour). Adicionalmente, as colunas auxiliares criadas durante o tratamento ("Full", "Consistent sum", "Diff") foram removidas antes da fase de modelação, uma vez que serviam apenas propósitos de diagnóstico.

3.5. Imputação de Valores Ausentes por Regressão

Para lidar com os valores ausentes nas colunas de tensão (identificados em 723 registos), optou-se por uma abordagem avançada baseada em modelos preditivos, em vez de métodos simples como a substituição pela média ou mediana. Esta decisão justifica-se pelo facto de os valores de tensão estarem correlacionados entre si e com as variáveis meteorológicas, permitindo uma estimativa mais precisa dos valores em falta.

Foram implementados três metanodes no workflow, cada um contendo um algoritmo de regressão diferente, treinado para prever os valores em falta com base nas restantes variáveis disponíveis. Cada metanode contém quatro pares Learner/Predictor, um para cada nível de tensão (Very High, High, Medium e Low Voltage). Os dados foram divididos internamente através de um "Rule-based Row Splitter" que separa os registos completos (usados para treino) dos registos com valores ausentes (usados para previsão).

Os três algoritmos testados e os respetivos resultados foram:

Algoritmo	R ²	Observações
Linear Regression	0.6436	Desempenho moderado
Simple Regression Tree (Decision Tree)	0.6355	Desempenho moderado
Gradient Boosted Trees (GBT)	0.8757	Melhor desempenho – selecionado

(ver Anexo 16 — Figura 16: Estatísticas dos modelos de regressão avaliados para imputação de valores ausentes.)

O modelo Gradient Boosted Trees obteve o melhor desempenho com um R² de 0.8757, superando significativamente a Regressão Linear (R² = 0.6436) e a Simple Regression Tree (R² = 0.6355). Consequentemente, o GBT foi selecionado para inferir os valores ausentes de "Low Voltage" e "Medium Voltage". Após todo o processo de limpeza e imputação, o dataset final resultou em 8732 registos consistentes e completos, prontos para a fase de modelação.

(ver Anexo 17 — Figura 17: Comparação detalhada dos modelos de regressão utilizados na imputação.)

3.6. Partição dos Dados

Para a avaliação dos modelos, o workflow suporta dois métodos de partição dos dados, seleccionáveis através de widgets interativos (Single Selection Widgets) que permitem ao utilizador escolher o método de validação pretendido sem necessidade de alterar o workflow:

Hold-out Validation: Os dados são divididos em 80% para treino e 20% para teste, através do nó "Table Partitioner" com amostragem estratificada pela variável alvo. Este método é mais rápido mas pode ser sensível à partição específica dos dados.

Cross-Validation (10 folds): Os dados são divididos em 10 partições, sendo cada uma utilizada alternadamente como conjunto de teste enquanto as restantes 9 servem de treino. Esta abordagem é implementada através dos nós "X_Partitioner" e "X_Aggregator" do KNIME e proporciona uma estimativa mais robusta do desempenho do modelo, reduzindo a variância associada a uma única partição dos dados.

A alternância entre os dois métodos é gerida por nós "CASE Switch Start" e "CASE Switch End", que direccionam o fluxo de dados para o ramo correspondente ao método seleccionado pelo utilizador.

4. Modelação

4.1. Seleção de Técnicas de Modelação

A fase de modelação englobou a aplicação de 17 algoritmos distintos, organizados em três categorias: modelos de classificação (10 algoritmos), modelos de regressão adaptados para classificação (7 algoritmos) e clustering (1 algoritmo). Para mitigar o desbalanceamento de classes observado no dataset, aplicaram-se técnicas de sobre-amostragem como SMOTE (Synthetic Minority Over-sampling Technique) e Equal Size Sampling nos modelos que beneficiam destas técnicas.

Os modelos de classificação implementados foram os seguintes:

#	Modelo	Descrição / Particularidades
1	Decision Tree	Árvore de decisão com poda; SMOTE + Equal Size Sampling
2	Tree Ensemble	Ensemble de árvores de decisão; SMOTE + Equal Size Sampling
3	Logistic Regression	Regressão logística multinomial
4	KNN	K-Nearest Neighbors com otimização automática de K (Parameter Optimization Loop)
5	Naive Bayes	Classificador probabilístico bayesiano
6	Random Forest	Floresta aleatória de árvores de decisão
7	Fuzzy & Random Forest	Combinação de Fuzzy Rule Learner com Random Forest
8	H2O GBM	Gradient Boosting Machine via framework H2O (com otimização de profundidade)
9	PNN	Probabilistic Neural Network
10	MLP	Multi-Layer Perceptron (rede neuronal feedforward)

Os modelos de regressão adaptados para classificação foram:

#	Modelo	Descrição / Particularidades
11	Simple Regression Tree	Árvore de regressão simples
12	Tree Ensemble (Regression)	Ensemble de árvores de regressão

13	PMML Simple Regression Tree	Árvore de regressão em formato PMML
14	PMML Gradient Boosted Trees	GBT de regressão em formato PMML
15	Linear Regression	Regressão linear múltipla
16	Random Forest (Regression)	Floresta aleatória de regressão
17	Keras Deep Learning	Rede neuronal profunda (Input + 4 Dense Layers); Adam optimizer, lr=0.001, 50 épocas, batch=100

Os modelos de regressão foram adaptados para classificação através da conversão das previsões numéricas contínuas em classes categóricas discretas. Este processo envolve: (1) arredondamento do valor previsto para o inteiro mais próximo (nó "Number Rounder"); (2) conversão para String (nó "Number to String"); e (3) mapeamento do valor numérico para o nome da classe correspondente através de um nó "Rule Engine (Dictionary)" que utiliza uma tabela de correspondência gerada por um "GroupBy" sobre os dados originais.

Adicionalmente, foi implementado um modelo de clustering não supervisionado (k-Medoids) com otimização automática do número de clusters. O metanode "Find the best k" implementa um ciclo iterativo que: (1) testa diferentes valores de k através de um "Table Row to Variable Loop Start"; (2) executa o k-Means para cada valor de k; (3) calcula o Silhouette Coefficient como métrica de qualidade; (4) seleciona o k com melhor coeficiente de silhueta. O resultado desta otimização indicou k=2 como o valor ótimo.

Para o modelo KNN, foi implementado um metanode de otimização denominado "Best Number of neighbors to consider" que utiliza um "Parameter Optimization Loop" para encontrar o melhor número de vizinhos (K). Este ciclo executa validação cruzada interna para cada valor candidato de K, avalia o desempenho através de um "Scorer", e seleciona automaticamente o valor ótimo.

O modelo Keras Deep Learning foi configurado com a seguinte arquitetura: uma camada de entrada (Keras Input Layer) que recebe 25 variáveis numéricas (tensões, variáveis meteorológicas e dummies de radiação), seguida de 4 camadas densas (Keras Dense Layers) com ativação linear. O treino utiliza o otimizador Adam (learning rate = 0.001, beta_1 = 0.9, beta_2 = 0.999), função de perda Mean Squared Error, 50 épocas e batch size de 100. A normalização dos dados de entrada foi aplicada previamente através de um nó "Normalizer".

4.2. Resultados

Os resultados obtidos são apresentados nas figuras e tabelas seguintes, organizados por método de validação. As métricas reportadas incluem a Exatidão Global (Overall Accuracy), o coeficiente Kappa de Cohen (Cohen's kappa), o Erro Global (Overall Error) e o Tempo de Execução em milissegundos.

4.2.1. Resultados com Cross-Validation (10 folds)

(ver Anexo 18 — Figura 18: Resultados dos 17 modelos utilizando Cross-Validation (10 folds).)

Na avaliação com Cross-Validation de 10 folds, os melhores resultados de classificação foram obtidos pelo KNN (95.67%), seguido do H2O GBM (95.34%), Random Forest (95.32%) e Tree Ensemble (95.29%). Entre os modelos de regressão adaptados, a PMML Simple Regression Tree destacou-se com 92.58%. Os piores resultados foram obtidos pelo Naive Bayes (36.91%), pela Regressão Linear (38.16%) e pelo Keras (38.57%), indicando que estes modelos são inadequados para este problema específico.

Modelo	Accuracy	Cohen's κ	Error	Tempo (ms)
Decision Tree	92.65%	0.9081	7.35%	130
Tree Ensemble	95.29%	0.9411	4.71%	126
Logistic Regression	79.93%	0.7491	20.07%	131
KNN	95.67%	0.9458	4.33%	125
Naive Bayes	36.91%	0.2120	63.09%	132
Random Forest	95.32%	0.9416	4.68%	130
Fuzzy & Random Forest	76.32%	0.7040	23.68%	132
H2O GBM	95.34%	0.9417	4.66%	133
PNN	65.81%	0.5727	34.19%	124
MLP	76.52%	0.7065	23.48%	93 625
Simple Regression Tree	82.11%	0.7764	17.89%	541
Tree Ensemble (Reg.)	89.31%	0.8663	10.69%	540
PMML Simple Reg. Tree	92.58%	0.9072	7.42%	542
PMML GBT (Reg.)	91.80%	0.8975	8.20%	542
Linear Regression	38.16%	0.2263	61.84%	537
Random Forest (Reg.)	89.82%	0.8727	10.18%	529
Keras	38.57%	0.2316	61.43%	1 065 766

4.2.2. Resultados com Hold-out Validation (80/20)

(ver Anexo 19 — Figura 19: Resultados dos 17 modelos utilizando Hold-out Validation (80/20).)

Na avaliação com Hold-out Validation (80% treino, 20% teste), o Tree Ensemble assumiu a liderança com 94.69%, seguido do Random Forest e H2O GBM (ambos com 94.53%) e do KNN (93.01%). A PMML Simple Regression Tree manteve a melhor performance entre os modelos de regressão com 91.77%.

Modelo	Accuracy	Cohen's κ	Error	Tempo (ms)
Decision Tree	90.48%	0.8811	9.52%	343
Tree Ensemble	94.69%	0.9337	5.31%	307
Logistic Regression	79.41%	0.7426	20.59%	316

KNN	93.01%	0.9126	6.99%	341
Naive Bayes	37.64%	0.2221	62.36%	313
Random Forest	94.53%	0.9316	5.47%	311
Fuzzy & Random Forest	79.93%	0.7492	20.07%	345
H2O GBM	94.53%	0.9316	5.47%	340
PNN	75.24%	0.6906	24.76%	338
MLP	78.36%	0.7295	21.64%	110 236
Simple Regression Tree	82.27%	0.7783	17.73%	105
Tree Ensemble (Reg.)	88.42%	0.8552	11.58%	107
PMML Simple Reg. Tree	91.77%	0.8972	8.23%	101
PMML GBT (Reg.)	91.28%	0.8910	8.72%	107
Linear Regression	45.74%	0.3206	54.26%	105
Random Forest (Reg.)	89.60%	0.8699	10.40%	100
Keras	42.52%	0.2806	57.48%	86 465

4.2.3. Resultados do Clustering

(ver Anexo 20 — Figura 20: Matriz de confusão e métricas do modelo de Clustering (*k*-Medoids, *k*=2).)

(ver Anexo 21 — Figura 21: Tabela detalhada do scorer do clustering com métricas por classe.)

O modelo de clustering *k*-Medoids com *k*=2 obteve uma exatidão global de apenas 30.69% (Cohen's kappa = 0.171) quando comparado com as 5 classes reais. A matriz de confusão revela que o algoritmo conseguiu apenas distinguir dois grupos: um correspondente aproximadamente ao "High Consumption" (683 registos corretamente atribuídos) e outro ao "Low Consumption" (1997 registos corretamente atribuídos). As classes intermédias (Medium, Medium-High e Medium-Low) foram sistematicamente mal classificadas, sendo distribuídas entre os dois clusters sem qualquer padrão discriminativo adequado. Dos 8732 registos totais, apenas 2680 foram corretamente classificados, enquanto 6052 foram incorretamente atribuídos.

4.3. Análise de Resultados

A análise dos resultados permite extrair diversas conclusões relevantes sobre o desempenho dos diferentes tipos de modelos aplicados ao problema de classificação do consumo energético.

Modelos de Classificação: Os modelos baseados em ensemble (Tree Ensemble, Random Forest, H2O GBM) e o KNN apresentaram consistentemente os melhores resultados, com exatidões superiores a 93% em ambos os métodos de validação. O KNN destacou-se particularmente na cross-validation (95.67%), beneficiando da otimização automática do

parâmetro K através do "Parameter Optimization Loop". A Decision Tree individual obteve resultados sólidos (~90-93%), demonstrando que a estrutura dos dados é bem capturada por modelos baseados em árvores. A Logistic Regression obteve resultados moderados (~79%), enquanto o Naive Bayes apresentou o pior desempenho entre os classificadores (~37%), sugerindo que a suposição de independência condicional entre variáveis não se verifica neste dataset, onde existem fortes correlações entre as variáveis de tensão.

Modelos de Regressão adaptados: Entre os modelos de regressão convertidos para classificação, a PMML Simple Regression Tree e o PMML Gradient Boosted Trees obtiveram resultados notáveis (>91%), demonstrando que a abordagem de regressão com posterior discretização pode ser eficaz quando as classes possuem uma ordenação natural (como é o caso dos níveis de consumo, que representam uma escala ordinal de baixo a alto). Em contraste, a Regressão Linear (~38-46%) e o modelo Keras (~39-43%) obtiveram resultados fracos, indicando que a relação entre as variáveis e a classe numérica não é adequadamente capturada por modelos lineares ou pela configuração específica da rede neuronal utilizada.

Redes Neurais: O MLP obteve resultados moderados (~77-78%), enquanto o PNN variou entre 66% (cross-validation) e 75% (hold-out). O modelo Keras, apesar da sua complexidade arquitetural (4 camadas densas, 50 épocas de treino), obteve resultados insatisfatórios (~39-43%). Este fraco desempenho pode ser atribuído a vários fatores: (1) a utilização da função de perda MSE, que não é ideal para problemas de classificação ordinal; (2) a ativação linear em todas as camadas, que limita a capacidade de modelar relações não-lineares; (3) a possível necessidade de mais épocas de treino ou de uma taxa de aprendizagem diferente. Note-se que o tempo de execução do Keras (>1 milhão de ms na cross-validation) é significativamente superior ao dos restantes modelos.

Clustering: O resultado do clustering (30.69%) confirma que a abordagem não supervisionada é inadequada para este problema com 5 classes. O Silhouette Coefficient indicou k=2 como ótimo, o que sugere que os dados possuem uma estrutura bimodal natural (consumo alto vs. consumo baixo), mas não apresentam separação clara entre as classes intermédias no espaço de features. Este resultado é consistente com a sobreposição observada na análise dos valores máximos e mínimos por classe (Figura 4).

Comparação entre métodos de validação: Os resultados da cross-validation são geralmente ligeiramente superiores aos do hold-out, o que é expectável dado que a cross-validation utiliza mais dados para treino em cada iteração (90% vs. 80%). A consistência entre ambos os métodos confirma que os modelos não apresentam sobreajustamento (overfitting) significativo e que os resultados são generalizáveis. A exceção mais notável é o KNN, que desce de 95.67% na cross-validation para 93.01% no hold-out, sugerindo uma ligeira sensibilidade à partição dos dados.

5. Avaliação

Com base nos resultados obtidos, procede-se à avaliação global do projeto e à identificação do melhor modelo para o problema de classificação do consumo energético.

O modelo KNN com otimização automática do parâmetro K é recomendado como o melhor modelo global, apresentando a maior exatidão na cross-validation (95.67%) e um desempenho robusto no hold-out (93.01%). O seu Cohen's kappa de 0.9458 indica uma concordância quase perfeita com as classes reais. Alternativamente, o Tree Ensemble oferece o melhor compromisso entre desempenho e estabilidade, sendo o melhor modelo no hold-out (94.69%) e o quarto melhor na cross-validation (95.29%), com a vantagem adicional de um tempo de execução reduzido.

Os elevados valores de exatidão (>93%) obtidos pelos melhores modelos indicam que as variáveis disponíveis no dataset (consumos parciais por nível de tensão, variáveis meteorológicas e informação temporal) possuem um forte poder discriminativo para a classificação do nível de consumo energético. A inclusão das variáveis temporais derivadas (hora, mês, estação) e a imputação inteligente de valores ausentes através do GBT contribuíram significativamente para a qualidade dos resultados finais.

Como sugestões de melhoria futura, destacam-se as seguintes possibilidades: (1) a otimização de hiperparâmetros para o modelo Keras, incluindo a experimentação com diferentes funções de perda (e.g., categorical cross-entropy), arquiteturas mais profundas com ativações não-lineares (ReLU, sigmoid) e taxas de aprendizagem adaptativas; (2) a exploração de técnicas de seleção de features mais sofisticadas, como Recursive Feature Elimination ou importância de variáveis baseada em Random Forest; (3) a implementação de ensemble stacking, combinando as previsões dos melhores modelos individuais (KNN, Tree Ensemble, Random Forest) num meta-modelo; (4) a exploração de algoritmos de clustering mais sofisticados (e.g., DBSCAN, Gaussian Mixture Models) que possam capturar melhor a estrutura multimodal dos dados; e (5) a experimentação com diferentes estratégias de balanceamento de classes, como undersampling da classe majoritária ou cost-sensitive learning.

6. Conclusão

O presente trabalho demonstrou com sucesso a aplicação de técnicas de aprendizagem automática à classificação do consumo energético em Portugal. O pipeline desenvolvido no KNIME Analytics Platform abrangeu todas as fases do modelo CRISP-DM, desde a compreensão do negócio até à avaliação dos modelos, passando por uma preparação de dados rigorosa e uma modelação abrangente.

A fase de preparação dos dados revelou-se particularmente desafiante e crucial para o sucesso do projeto. A identificação e correção de inconsistências tipográficas na variável alvo (8 variantes diferentes normalizadas para 5 classes), a remoção de 7 registos com datas inválidas, a eliminação de variáveis redundantes (precipitation/rain, snowfall) e, sobretudo, a imputação inteligente de 723 registos com valores ausentes através de modelos de regressão (GBT com $R^2 = 0.8757$) foram determinantes para a qualidade do dataset final de 8732 registos.

Na fase de modelação, os 17 algoritmos supervisionados e o modelo de clustering foram avaliados de forma sistemática e comparável. Os algoritmos supervisionados baseados em ensemble e em instâncias apresentaram resultados excelentes, com o KNN a atingir 95.67% de exatidão na cross-validation e o Tree Ensemble a liderar no hold-out com 94.69%. Estes resultados comprovam que as variáveis meteorológicas e os padrões temporais possuem um forte poder preditivo sobre o nível de consumo energético.

A abordagem não supervisionada (clustering com k-Medoids) revelou-se insuficiente para capturar a granularidade das cinco classes de consumo, obtendo apenas 30.69% de exatidão com $k=2$. Este resultado reforça a adequação da formulação do problema como uma tarefa de classificação supervisionada e sugere que as fronteiras entre as classes intermédias não são naturalmente separáveis no espaço de features sem a orientação proporcionada pelas etiquetas de classe.

Em suma, o workflow desenvolvido constitui uma solução robusta, reproduzível e interativa para a classificação do consumo energético, com potencial de aplicação prática na gestão e previsão da procura elétrica em Portugal. A utilização de widgets interativos no KNIME permite ao utilizador selecionar o método de validação e explorar os resultados de forma dinâmica, tornando o workflow uma ferramenta versátil para análise e decisão.

4. Dataset Escolhido — Individual Household Electric Power Consumption

Nas subsecções seguintes apresenta-se em detalhe o trabalho desenvolvido sobre o dataset escolhido pelo grupo, seguindo igualmente as fases da metodologia CRISP-DM.

1. Estudo de Negócio

O dataset escolhido para a realização desta segunda componente do trabalho prático intitula-se "Individual Household Electric Power Consumption" e encontra-se disponível no repositório UCI Machine Learning Repository (<https://archive.ics.uci.edu/dataset/235/individual+household+electric+power+consumption>).

Este conjunto de dados contém medições do consumo de energia elétrica de uma habitação individual localizada em Sceaux, na região de Paris, França, recolhidas ao longo de um período de aproximadamente quatro anos, entre dezembro de 2006 e novembro de 2010, com uma resolução temporal de um minuto.

A escolha deste dataset foi motivada pela sua complementaridade com o dataset atribuído, ambos centrados na temática do consumo energético, permitindo assim explorar diferentes perspetivas e abordagens de modelação sobre um domínio comum. Enquanto o dataset atribuído aborda o consumo energético a nível nacional em Portugal, este dataset permite uma análise granular ao nível de uma habitação individual, oferecendo desafios distintos em termos de pré-processamento, engenharia de atributos e modelação preditiva.

O setor energético enfrenta atualmente desafios significativos relacionados com a otimização da produção, distribuição e consumo de energia. A capacidade de prever com precisão o consumo energético de habitações individuais reveste-se de importância crescente, tanto para os consumidores finais como para os operadores de rede, na medida em que permite uma melhor gestão dos recursos, a redução de desperdícios e a promoção da eficiência energética.

Neste contexto, o objetivo principal deste estudo é desenvolver modelos de Machine Learning capazes de: (1) classificar o nível de consumo energético em categorias discretas (classificação), (2) prever o valor contínuo da potência ativa consumida (regressão), e (3) identificar padrões intrínsecos de consumo através de técnicas de aprendizagem não supervisionada (clustering). A análise abrange a exploração detalhada dos dados, a validação da sua consistência com princípios físicos fundamentais, e a avaliação comparativa de múltiplos algoritmos de aprendizagem automática.

2 Análise dos Dados

2.1 Análise do Dataset

O dataset original é composto por 2.075.259 instâncias e 9 atributos, representando medições efetuadas a cada minuto. Os atributos incluem variáveis temporais (Date, Time) e variáveis numéricas relativas ao consumo energético: Global_active_power (potência ativa global, em kilowatt), Global_reactive_power (potência reativa global, em kilowatt), Voltage (tensão, em volt), Global_intensity (intensidade de corrente global, em ampere), Sub_metering_1 (sub-medição da cozinha, em watt-hora), Sub_metering_2 (sub-medição da lavandaria, em watt-hora) e Sub_metering_3 (sub-medição do aquecedor de água e ar condicionado, em watt-hora).

A primeira etapa da análise consistiu na verificação dos tipos de dados de cada coluna do dataset. Através do nó Extract Table Spec do KNIME, foi possível identificar que todas as variáveis numéricas se encontravam inicialmente armazenadas como strings, tendo sido necessário proceder à sua conversão para tipos numéricos adequados através de nós String to Number.

(ver Anexo 22 — Figura 1: Tipos de dados de cada coluna do dataset após conversão.)

A análise de valores omissos (missing values) revelou a existência de linhas com dados em falta. Uma investigação mais aprofundada, realizada através de nós Table View, demonstrou que todas as linhas com valores omissos estavam completamente vazias em todos os atributos numéricos, correspondendo a períodos em que o sistema de medição esteve inativo ou apresentou falhas de registo. Esta constatação é relevante para a decisão de tratamento destes valores, uma vez que a imputação não seria adequada neste contexto.

(ver Anexo 23 — Figura 2: Verificação de que todas as linhas com valores omissos estão completamente vazias.)

Adicionalmente, foi realizada uma verificação da integridade dos dados temporais. Através de um nó Rule Engine, foram definidas regras para identificar datas inválidas, tais como dias inexistentes em determinados meses (e.g., 31 de fevereiro) ou valores fora dos intervalos esperados. A análise confirmou a ausência de datas inválidas no dataset.

(ver Anexo 24 — Figura 3: Verificação do número de datas inválidas no dataset.)

De forma análoga, os valores temporais (horas, minutos e segundos) foram inspecionados para garantir que se encontravam dentro dos intervalos válidos (0-23 para horas, 0-59 para minutos). Não foram detetadas anomalias nos valores temporais.

(ver Anexo 25 — Figura 4: Pesquisa por valores de tempo inválidos no dataset.)

Uma etapa fundamental da análise consistiu na validação da consistência dos dados com os princípios físicos da eletricidade. Segundo a Lei de Ohm e a relação fundamental da potência elétrica ($P = V \times I$), a potência ativa deve ser proporcional ao produto da tensão pela intensidade da corrente. Para verificar esta relação, foi aplicado um filtro (nó Row Filter) que seleccionou apenas as instâncias com tensão entre 234V e 236V (aproximadamente constante), permitindo observar a relação linear entre potência e intensidade.

(ver Anexo 26 — Figura 5: Verificação da Lei de Ohm — relação entre potência e intensidade para tensão constante (~235V).)

O gráfico de dispersão (Scatter Plot) entre a intensidade global e a potência ativa global confirma inequivocamente a relação de proporcionalidade direta entre estas duas variáveis, validando a consistência física dos dados. Esta observação tem implicações diretas na modelação, uma vez que a inclusão da variável Global_intensity como preditor da Global_active_power torna o problema de regressão trivial.

(ver Anexo 27 — Figura 6: Relação de proporcionalidade direta entre a intensidade da corrente e a potência ativa.)

Foi também analisada a conservação de energia, verificando a relação entre o consumo total medido pela potência ativa global e a soma das três sub-medições. A diferença entre estes valores corresponde à energia consumida por equipamentos não monitorizados individualmente.

(ver Anexo 28 — Figura 7: Análise da conservação de energia e relação entre sub-medições e consumo total.)

2.2 Conclusão sobre o Dataset

A análise exploratória do dataset permitiu identificar as seguintes características e problemas: (1) presença de valores omissos correspondentes a linhas completamente vazias, indicando falhas no sistema de medição; (2) ausência de datas ou horas inválidas; (3) consistência dos dados com os princípios físicos da eletricidade (Lei de Ohm); (4) existência de uma relação determinística entre a potência ativa, a tensão e a intensidade da corrente, que deve ser considerada na fase de modelação; e (5) a corrente foi medida em incrementos discretos de 0.2 A, refletindo a resolução do equipamento de medição.

(ver Anexo 29 — Figura 8: Observação de que a corrente foi medida em incrementos de 0.2 A.)

3 Preparação dos Dados

3.1 Limpeza dos Dados (Pré-processamento)

A limpeza dos dados envolveu as seguintes operações, implementadas no componente "Data Visualization-Treatment-Exploration" (Component #446) do workflow KNIME:

Conversão de Tipos: Os atributos numéricos, originalmente armazenados como strings no ficheiro de texto, foram convertidos para os tipos adequados (Double) através de múltiplos nós String to Number (#354, #357, #367, #390, #393, #618). As variáveis temporais foram igualmente convertidas para o formato Date&Time através de nós String to Date&Time (#381, #382, #384).

Tratamento de Valores Omissos: Dado que todas as linhas com valores omissos estavam completamente vazias (sem qualquer medição válida), optou-se pela remoção integral destas linhas através do nó Missing Value (#379), configurado com a estratégia "Remove Row". A imputação de valores não foi considerada adequada neste caso, uma vez que não existia informação parcial que pudesse ser aproveitada.

Validação de Datas: Através do nó Rule Engine (#266), foram implementadas regras para identificar e marcar datas potencialmente inválidas, tais como o dia 31 em meses com apenas 30 dias, ou dias superiores a 28/29 em fevereiro. A verificação confirmou a ausência de datas inválidas no dataset.

3.2 Construção dos Dados (Feature Engineering)

Para enriquecer o dataset e facilitar a análise temporal, foram criadas novas variáveis derivadas a partir dos atributos existentes:

Extração de Componentes Temporais: A partir das variáveis Date e Time, foram extraídos os componentes Month (Number), Hour, Year e Day of Week através do nó Date&Time Part Extractor (#413). Estas variáveis permitem captar padrões sazonais, diários e semanais no consumo energético.

Cálculo de Sub_metering_other: Foi criada uma nova variável que representa a energia consumida por equipamentos não monitorizados individualmente, calculada através do nó Math Formula (#399) com a expressão: $(\$Global_active_power/60) - \$Sub_metering_1\$ -$

\$Sub_metering_2\$ - \$Sub_metering_3\$. Esta variável complementa as três sub-medições existentes, proporcionando uma visão completa da distribuição do consumo.

Discretização de Variáveis Temporais: A variável Month foi discretizada em quatro categorias correspondentes às estações do ano, utilizando o nó Auto-Binner (#278) seguido de um nó Rule Engine (#277) para atribuir os rótulos semânticos: Inverno (Bin 1), Primavera (Bin 2), Verão (Bin 3) e Outono (Bin 4). De forma análoga, a variável Hour foi discretizada em quatro períodos do dia através de um nó Rule Engine (#46): Madrugada (Bin 1), Manhã (Bin 2), Tarde (Bin 3) e Noite (Bin 4).

Criação da Variável Alvo para Classificação: A variável Global_active_power foi discretizada em cinco classes de consumo através do nó Rule Engine (#611): "Low Consumption" (Bin 1), "Medium-Low Consumption" (Bin 2), "Medium Consumption" (Bin 3), "Medium-High Consumption" (Bin 4) e "High Consumption" (Bin 5). Esta variável categórica serve como variável alvo para os modelos de classificação.

3.3 Seleção de Dados

Devido à elevada dimensão do dataset original (mais de 2 milhões de instâncias), foi aplicada uma técnica de amostragem estratificada através do nó Row Sampler (#617), utilizando a variável Global_active_power (Binned) como coluna de estratificação. Esta abordagem garante que a distribuição das classes de consumo no subconjunto amostrado é representativa da distribuição no dataset completo. O dataset resultante para treino e avaliação dos modelos é composto por 20.752 instâncias e 10 atributos.

Os atributos utilizados como preditores na fase de modelação incluem:

Global_reactive_power, Voltage, Global_intensity, Sub_metering_1, Sub_metering_2, Sub_metering_3, Month (Number), Hour e Year. Para o estudo de ablação (ablation study) na regressão, a variável Global_intensity foi removida do conjunto de preditores.

3.4 Partição dos Dados

Para a avaliação dos modelos supervisionados, foram implementados dois métodos de reamostragem, selecionáveis através de um Single Selection Widget (#214) no componente "Models Train" (#526):

Hold-out Validation: Os dados foram divididos numa proporção de 70% para treino e 30% para teste, conforme configurado no Double Widget (#215). A partição foi realizada através de nós Table Partitioner presentes em cada metanode de modelo.

Cross-Validation: Foi implementada validação cruzada através de nós X-Partitioner e X-Aggregator, permitindo uma avaliação mais robusta do desempenho dos modelos ao utilizar múltiplas partições dos dados para treino e teste.

4 Exploração dos Dados

A exploração aprofundada dos dados foi realizada após a fase de limpeza e pré-processamento, com o objetivo de identificar padrões, tendências e relações entre as

variáveis que possam informar a seleção e configuração dos modelos de aprendizagem automática.

A análise de correlação linear, realizada através do nó Linear Correlation (#441), revelou as relações entre todas as variáveis numéricas do dataset. A matriz de correlação evidencia uma correlação extremamente forte entre Global_active_power e Global_intensity (próxima de 1), confirmando a relação física $P = V \times I$. Observa-se também uma correlação moderada entre Sub_metering_3 e Global_active_power, sugerindo que o aquecedor de água e ar condicionado representam uma parcela significativa do consumo total.

(ver Anexo 30 — Figura 9: Matriz de correlação linear entre as variáveis numéricas do dataset.)

A análise do consumo médio por estação do ano, obtida através de nós GroupBy (#265) e Bar Chart (#412), evidenciou um padrão sazonal claro: o consumo é significativamente mais elevado durante o inverno (aproximadamente 1300W em média) e mais reduzido no verão (aproximadamente 750W). Este padrão é consistente com a utilização de sistemas de aquecimento durante os meses mais frios.

(ver Anexo 31 — Figura 10: Potência ativa média por estação do ano.)

A análise do consumo por período do dia revelou que o período noturno apresenta o maior consumo médio (aproximadamente 1500W), seguido pela manhã e pela tarde, enquanto a madrugada regista os valores mais baixos (aproximadamente 480W). Este padrão reflete as rotinas diárias típicas de uma habitação, com maior atividade e utilização de equipamentos durante o período noturno (após o regresso do trabalho).

(ver Anexo 32 — Figura 11: Potência ativa média por período do dia.)

A exploração detalhada do consumo horário por dia da semana e por mês permitiu identificar variações mais granulares nos padrões de consumo. Os heatmaps gerados através de nós Heatmap (JavaScript) (#415, #445) e gráficos de linha (Line Plot #432) revelam que os fins de semana apresentam um perfil de consumo ligeiramente diferente dos dias úteis, com picos de consumo mais distribuídos ao longo do dia.

(ver Anexo 33 — Figura 12: Consumo horário por dia da semana.)

(ver Anexo 34 — Figura 13: Consumo total médio por dia da semana para cada hora do dia.)

(ver Anexo 35 — Figura 14: Consumo total médio por mês para cada hora do dia.)

A análise da evolução do consumo ao longo do tempo demonstrou uma certa estabilidade nos padrões anuais, com variações sazonais consistentes entre os diferentes anos do período de medição. A soma da potência ao longo dos meses confirma o padrão sazonal identificado anteriormente, com picos durante os meses de inverno.

(ver Anexo 36 — Figura 15: Soma da potência consumida ao longo dos meses.)

(ver Anexo 37 — Figura 16: Evolução da potência ao longo do ano de 2007.)

A análise da proporção das sub-medidas ao longo dos anos revelou uma distribuição relativamente estável, com a Sub_metering_3 (aquecedor de água e ar condicionado) a representar consistentemente a maior parcela do consumo monitorizado individualmente.

(ver Anexo 38 — Figura 17: Proporção das sub-medidas ao longo dos anos.)

5 Modelação

5.1 Seleção de Técnicas de Modelação

A fase de modelação foi implementada no componente "Models Train" (#526) do workflow KNIME, que integra uma arquitetura modular com widgets de configuração que permitem seleccionar dinamicamente o tipo de tarefa (classificação, regressão ou clustering), o método de validação (hold-out ou cross-validation) e o algoritmo específico a utilizar. Foram desenvolvidos modelos para três tipos de tarefas de Machine Learning:

Modelos de Classificação (10 algoritmos): Decision Tree (#195), Tree Ensemble (#495), Logistic Regression (#497), K-Nearest Neighbors — KNN (#498), Naive Bayes (#501), Random Forest (#502), Fuzzy & Random Forest (#505), H2O Gradient Boosted Machine (#506), Probabilistic Neural Network — PNN (#509) e Multi-Layer Perceptron — MLP (#510). A variável alvo é Global_active_power (Binned) com 5 classes de consumo.

Modelos de Regressão (7 algoritmos): Simple Regression Tree (#513), Tree Ensemble Regression (#515), PMML Simple Regression Tree (#519), PMML Gradient Boosted Trees Regression (#521), Linear Regression (#523), Random Forest Learner Regression (#525) e Keras Deep Learning (#541). A variável alvo é Global_active_power (valor contínuo). Para o modelo Keras, foi configurada uma rede neuronal com 4 camadas densas, otimizador Adam, função de perda Mean Squared Error, 50 épocas e batch size de 100.

Modelo de Clustering: k-Medoids (método CLARANS), implementado no metanode Clustering (#542). Para determinar o número ideal de clusters, foi implementado um processo iterativo ("Find the best k" #213) que testa valores de k entre 2 e 10, utilizando o Coeficiente de Silhueta como métrica de avaliação. O algoritmo k-Means é utilizado internamente para cada valor de k, e o melhor k é seleccionado automaticamente.

5.2 Resultados

Cross-Validation (Classificação)

Os resultados da avaliação dos modelos de classificação com Cross-Validation são apresentados na figura seguinte. Os algoritmos baseados em ensembles de árvores de decisão destacam-se claramente: Random Forest obteve a maior Overall Accuracy (95.23%) e o maior Cohen's Kappa (0.9403), seguido de perto pelo Tree Ensemble (Accuracy: 95.17%, Kappa: 0.9396). O modelo H2O GBM também apresentou um desempenho excelente (Accuracy: 94.71%). Em contraste, o algoritmo PNN revelou-se completamente inadequado para este problema (Accuracy: 20.57%, Kappa: 0.0071), sugerindo que a sua arquitetura não é capaz de modelar as fronteiras de decisão entre as cinco classes de consumo.

(ver Anexo 39 — Figura 18: Resultados dos modelos de classificação com Cross-Validation.)

Hold-out Validation (Classificação)

A avaliação com Hold-out Validation (70/30) confirmou as tendências observadas na validação cruzada. Os modelos Random Forest (Accuracy: 95.13%) e Tree Ensemble (Accuracy: 95.12%) mantiveram-se como os mais precisos. Destaca-se a melhoria do Fuzzy & Random Forest no hold-out (Accuracy: 84.77%) em comparação com a cross-validation (Accuracy: 75.96%), sugerindo alguma sensibilidade deste modelo à partição específica dos dados. O tempo de execução do MLP foi significativamente superior aos restantes modelos (188.756 ms vs. ~130 ms), refletindo a complexidade computacional do treino de redes neurais.

(ver Anexo 40 — Figura 19: Resultados dos modelos de classificação com Hold-out Validation (70/30).)

Cross-Validation (Regressão — com Global_intensity)

Os resultados iniciais da regressão, utilizando todas as variáveis preditoras incluindo Global_intensity, revelaram um desempenho excepcional para a maioria dos modelos. O modelo de Regressão Linear obteve um R^2 de 0.9984 e o PMML Gradient Boosted Trees alcançou R^2 de 0.9983, ambos com erros absolutos médios (MAE) inferiores a 27W. Estes resultados são expectáveis dado que a relação $P = V \times I$ torna a previsão da potência a partir da intensidade um problema essencialmente determinístico. A exceção notável é o modelo Keras, que obteve um R^2 de apenas 0.2949, indicando dificuldades de convergência durante o treino.

(ver Anexo 41 — Figura 20: Resultados dos modelos de regressão com Cross-Validation (com Global_intensity).)

Hold-out Validation (Regressão — com Global_intensity)

A avaliação com hold-out confirmou os resultados da cross-validation, com todos os modelos (exceto o Keras na cross-validation) a obterem R^2 superior a 0.97. Nesta avaliação, o modelo Keras obteve um R^2 de 0.9982, sugerindo que o resultado inferior na cross-validation pode ter sido causado por instabilidade no treino em determinadas partições dos dados.

(ver Anexo 42 — Figura 21: Resultados dos modelos de regressão com Hold-out Validation (com Global_intensity).)

Cross-Validation (Regressão — sem Global_intensity — Ablation Study)

Para avaliar a capacidade preditiva dos modelos num cenário mais realista, onde a intensidade global não é conhecida a priori (uma vez que esta variável é essencialmente redundante com a potência ativa), foi realizado um estudo de ablação (ablation study) removendo Global_intensity do conjunto de preditores. Como esperado, o desempenho de todos os modelos diminuiu significativamente, revelando a verdadeira dificuldade do problema de previsão.

Neste cenário, os modelos baseados em ensembles de árvores demonstraram a maior robustez: Random Forest Learner (R^2 : 0.8472), Tree Ensemble (R^2 : 0.8471) e PMML Gradient Boosted Trees (R^2 : 0.8427). O modelo de Regressão Linear sofreu uma queda mais acentuada (R^2 : 0.7557), indicando que a relação entre os preditores restantes e a potência ativa não é

puramente linear. O modelo Keras apresentou o pior desempenho (R^2 : 0.1353), sugerindo problemas de convergência ou inadequação da arquitetura da rede para este problema sem a variável determinística.

(ver Anexo 43 — Figura 22: Resultados dos modelos de regressão com Cross-Validation (sem Global_intensity).)

Hold-out Validation (Regressão — sem Global_intensity — Ablation Study)

A avaliação com hold-out sem a variável Global_intensity confirmou as tendências observadas na cross-validation. Os modelos Random Forest (R^2 : 0.8472) e Tree Ensemble (R^2 : 0.8469) mantiveram-se como os mais robustos. Notavelmente, o modelo Keras obteve neste caso um R^2 de 0.7471, significativamente superior ao resultado da cross-validation (0.1353), reforçando a hipótese de instabilidade no treino desta rede neuronal.

(ver Anexo 44 — Figura 23: Resultados dos modelos de regressão com Hold-out Validation (sem Global_intensity).)

Clustering (k-Medoids)

O modelo de clustering k-Medoids, após a determinação automática do melhor k através do Coeficiente de Silhueta (testando k de 2 a 10), identificou k=3 como o número ideal de clusters. A avaliação foi realizada comparando os clusters gerados com as cinco classes de consumo previamente definidas, através de um Scorer (JavaScript) (#247).

A matriz de confusão revela que o modelo agrupou as instâncias em apenas três clusters, correspondendo aproximadamente às categorias "High", "Low" e "Medium". O modelo conseguiu identificar corretamente 100% das instâncias da classe "Low Consumption" (4099 instâncias) e 52.37% da classe "High Consumption" (2152 de 4109 instâncias). No entanto, falhou completamente na identificação das classes intermédias "Medium-High" e "Medium-Low", atribuindo-as integralmente aos clusters "Medium" e "Low", respetivamente.

As estatísticas globais refletem este desempenho limitado: Overall Accuracy de 34.97%, Overall Error de 65.03% e Cohen's Kappa de 0.187. Estes resultados sugerem que a segmentação artificial do consumo em cinco classes não corresponde à estrutura natural dos dados, que apresenta apenas três agrupamentos bem definidos. Esta conclusão é consistente com a natureza contínua da variável de potência, onde as fronteiras entre classes adjacentes são inerentemente difusas.

(ver Anexo 45 — Figura 24: Matriz de confusão e estatísticas globais do modelo de clustering (k-Medoids).)

6. Análise de Resultados

A análise comparativa dos resultados obtidos permite extrair diversas conclusões relevantes sobre o desempenho dos diferentes algoritmos e a natureza do problema em estudo.

No que respeita à classificação, os algoritmos baseados em ensembles de árvores de decisão (Random Forest, Tree Ensemble) demonstraram ser consistentemente superiores, com precisões acima de 95% em ambos os métodos de validação. Este resultado é compreensível

dado que estes algoritmos são particularmente eficazes em problemas com múltiplas classes e relações não-lineares entre os atributos. O desempenho catastrófico do PNN ($\approx 20\%$) indica que este algoritmo não é adequado para problemas de classificação multiclasse com esta complexidade. O MLP, apesar de obter resultados razoáveis ($\approx 91\%$), requer um tempo de execução desproporcionalmente elevado em comparação com os modelos baseados em árvores.

Na regressão, a análise com e sem a variável `Global_intensity` evidenciou um aspeto fundamental: a relação determinística $P = V \times I$ torna o problema trivial quando a intensidade é incluída como preditor. O verdadeiro desafio reside na previsão da potência sem esta variável, cenário em que os modelos de ensemble (Random Forest, Tree Ensemble, Gradient Boosted Trees) se destacam com R^2 entre 0.84 e 0.85. A Regressão Linear, embora excelente no cenário com intensidade (R^2 : 0.9984), sofre uma queda significativa sem esta variável (R^2 : 0.7557), confirmando a existência de relações não-lineares importantes entre os restantes preditores e a potência ativa.

O clustering revelou que a estrutura natural dos dados de consumo energético apresenta três agrupamentos distintos (baixo, médio e alto consumo), e não cinco como definido artificialmente. Esta informação é valiosa para aplicações práticas de segmentação de consumidores e definição de tarifas energéticas.

7. Conclusão

A análise do dataset "Individual Household Electric Power Consumption" permitiu desenvolver e avaliar com sucesso múltiplos modelos de Machine Learning para a previsão e classificação do consumo energético de uma habitação individual. Os principais contributos deste estudo incluem:

(1) A validação da consistência dos dados com os princípios físicos da eletricidade, nomeadamente a Lei de Ohm, proporcionando confiança na qualidade das medições; (2) A identificação de padrões temporais significativos (sazonais, diários e semanais) que influenciam o consumo energético; (3) A demonstração de que os algoritmos de ensemble de árvores de decisão (Random Forest e Tree Ensemble) são os mais adequados e robustos para este tipo de problema, tanto em classificação como em regressão; (4) A realização de um ablation study que evidenciou a importância de avaliar os modelos em cenários realistas, sem variáveis deterministicamente correlacionadas com o alvo; e (5) A constatação de que a estrutura natural dos dados sugere três perfis de consumo distintos, informação relevante para aplicações práticas de gestão energética.

Como trabalho futuro, sugere-se a exploração de técnicas de seleção de atributos mais sofisticadas, o tuning de hiperparâmetros dos modelos de melhor desempenho, a experimentação com arquiteturas de redes neuronais mais adequadas (e.g., LSTM para captar dependências temporais), e a integração de dados meteorológicos externos que possam melhorar a capacidade preditiva dos modelos no cenário sem a variável de intensidade.

5. Conclusão Final

O presente trabalho permitiu a aplicação prática e consolidada dos conhecimentos adquiridos na unidade curricular de Aprendizagem e Decisão Inteligentes, através da exploração de dois conjuntos de dados distintos mas complementares no domínio do consumo energético. A utilização da plataforma KNIME Analytics Platform revelou-se uma escolha robusta para a implementação de todo o ciclo de vida dos projetos de ciência de dados, permitindo um seguimento rigoroso da metodologia CRISP-DM e a construção visual de pipelines reprodutíveis e modulares.

No que diz respeito ao dataset atribuído (Consumo de Energia Elétrica em Portugal), o principal desafio centrou-se na preparação dos dados, nomeadamente na normalização da variável alvo, na correção de inconsistências tipográficas e de tipos de dados, na eliminação de variáveis redundantes e, sobretudo, na imputação inteligente de 723 registos com valores ausentes através de um modelo de Gradient Boosted Trees ($R^2 = 0.8757$). A fase de modelação envolveu 17 algoritmos supervisionados e um modelo de clustering, dos quais os modelos baseados em instâncias (KNN, com 95,67% de exatidão em cross-validation) e em ensembles de árvores (Tree Ensemble, com 94,69% em hold-out) se destacaram claramente como os mais eficazes na classificação multiclasse do nível de consumo nacional.

Por seu turno, a análise do dataset escolhido (Individual Household Electric Power Consumption) ofereceu uma perspetiva microscópica do consumo energético, ao nível de uma habitação individual. A validação dos princípios físicos da eletricidade, nomeadamente a Lei de Ohm ($P = V \times I$), destacou a importância do conhecimento do domínio na fase de modelação e motivou a realização de um estudo de ablação, em que se removeu a variável `Global_intensity` para avaliar o desempenho dos modelos num cenário mais realista. Esse estudo evidenciou a robustez dos algoritmos de ensemble (Random Forest e Tree Ensemble com $R^2 \approx 0,847$) face a abordagens lineares ou neurais menos adaptadas. A análise de clustering, por sua vez, revelou que a estrutura natural dos dados se organiza em três agrupamentos distintos (consumo baixo, médio e alto), informação relevante para aplicações práticas de segmentação de consumidores e definição de tarifas.

Em ambos os projetos, os modelos não supervisionados (k-Medoids) revelaram-se insuficientes para capturar a granularidade das cinco classes definidas, reforçando a adequação da formulação dos problemas como tarefas de classificação supervisionada e sugerindo que as fronteiras entre classes intermédias não são naturalmente separáveis sem a orientação proporcionada pelas etiquetas de classe.

De um modo transversal, ambos os projetos sublinham a importância de um pré-processamento meticuloso, de uma engenharia de atributos cuidadosa e de uma avaliação crítica dos modelos face ao contexto específico do problema. Como direções de trabalho futuro, sugere-se: a otimização de hiperparâmetros em modelos como o Keras Deep Learning,

recorrendo a funções de perda mais adequadas à classificação ordinal e a arquiteturas com ativações não-lineares; a exploração de técnicas de seleção de atributos mais sofisticadas (Recursive Feature Elimination, importância baseada em Random Forest); a implementação de ensemble stacking, combinando as previsões dos melhores modelos individuais; a experimentação com algoritmos de clustering alternativos (DBSCAN, Gaussian Mixture Models); a aplicação de redes recorrentes (e.g., LSTM) para captar dependências temporais de longo prazo; e a integração de dados meteorológicos externos no dataset escolhido. As soluções desenvolvidas apresentam um elevado potencial de aplicação prática na gestão e previsão da procura elétrica, contribuindo para sistemas energéticos mais eficientes e sustentáveis, tanto à escala nacional como doméstica.

6. Referências Bibliográficas

Para suportar o trabalho desenvolvido, foi consultado o material disponibilizado nas aulas da unidade curricular, bem como as seguintes obras de referência na área de Machine Learning e Aprendizagem Automática:

- Michell, T. (2017). Machine Learning. McGraw Hill. ISBN: 978-1259096952.
- Alpaydin, E. (2014). Introduction to Machine Learning. The MIT Press. ISBN: 978-0-262-02818-9.
- Engelbrecht, A. (2007). Computational Intelligence: An Introduction (2nd ed.). Wiley & Sons. ISBN: 978-0470035610.
- Hastie, T., Tibshirani, R., & Friedman, J. (2016). The Elements of Statistical Learning: Data Mining, Inference, and Prediction (12th ed.). Springer. ISBN: 978-0387848570.
- Murphy, K. P. (2012). Machine Learning: A Probabilistic Perspective (4th ed.). The MIT Press. ISBN: 978-0262018029.
- KNIME AG. KNIME Analytics Platform — Documentação Oficial. Disponível em: <https://www.knime.com/>.
- UCI Machine Learning Repository (2010). Individual Household Electric Power Consumption Data Set. Disponível em: <https://archive.ics.uci.edu/dataset/235/individual+household+electric+power+consumption>.

Anexo 1

☐	RowID	↕	Column Name	↕	Column Type	↕
☐	RowID		RowID		Number (Integer)	
☐	Date/Time		Date/Time		String	
☐	Very High Voltage (kWh)		Very High Voltage (kWh)		Number (Float)	
☐	High Voltage (kWh)		High Voltage (kWh)		Number (Float)	
☐	Medium Voltage (kWh)		Medium Voltage (kWh)		String	
☐	Low Voltage (kWh)		Low Voltage (kWh)		Number (Float)	
☐	Total (kWh)		Total (kWh)		String	
☐	temperature_2m (°C)		temperature_2m (°C)		Number (Float)	
☐	relative_humidity_2m (%)		relative_humidity_2m (%)		Number (Float)	
☐	precipitation (mm)		precipitation (mm)		Number (Float)	

Showing 1 to 10 of 24 entries

Previous

1

2

3

Next

Figura 1: Tipos de dados das colunas do dataset original, conforme identificados pelo KNIME.

Anexo 2

Model	Dataset	Dataset Size	Dataset Type	Dataset Source	Dataset Description	Dataset Features	Dataset Labels	Dataset Metrics	Dataset Status	Dataset Version	Dataset Date	Dataset Author	Dataset License	Dataset Tags	Dataset Notes
Model 1	Dataset 1	10000	Classification	Source 1	Description 1	Feature 1, Feature 2, Feature 3	Label 1	Metric 1, Metric 2, Metric 3	Status 1	Version 1	Date 1	Author 1	License 1	Tags 1	Notes 1
Model 2	Dataset 2	20000	Regression	Source 2	Description 2	Feature 1, Feature 2, Feature 3	Label 2	Metric 1, Metric 2, Metric 3	Status 2	Version 2	Date 2	Author 2	License 2	Tags 2	Notes 2
Model 3	Dataset 3	30000	Classification	Source 3	Description 3	Feature 1, Feature 2, Feature 3	Label 3	Metric 1, Metric 2, Metric 3	Status 3	Version 3	Date 3	Author 3	License 3	Tags 3	Notes 3
Model 4	Dataset 4	40000	Regression	Source 4	Description 4	Feature 1, Feature 2, Feature 3	Label 4	Metric 1, Metric 2, Metric 3	Status 4	Version 4	Date 4	Author 4	License 4	Tags 4	Notes 4
Model 5	Dataset 5	50000	Classification	Source 5	Description 5	Feature 1, Feature 2, Feature 3	Label 5	Metric 1, Metric 2, Metric 3	Status 5	Version 5	Date 5	Author 5	License 5	Tags 5	Notes 5
Model 6	Dataset 6	60000	Regression	Source 6	Description 6	Feature 1, Feature 2, Feature 3	Label 6	Metric 1, Metric 2, Metric 3	Status 6	Version 6	Date 6	Author 6	License 6	Tags 6	Notes 6
Model 7	Dataset 7	70000	Classification	Source 7	Description 7	Feature 1, Feature 2, Feature 3	Label 7	Metric 1, Metric 2, Metric 3	Status 7	Version 7	Date 7	Author 7	License 7	Tags 7	Notes 7
Model 8	Dataset 8	80000	Regression	Source 8	Description 8	Feature 1, Feature 2, Feature 3	Label 8	Metric 1, Metric 2, Metric 3	Status 8	Version 8	Date 8	Author 8	License 8	Tags 8	Notes 8
Model 9	Dataset 9	90000	Classification	Source 9	Description 9	Feature 1, Feature 2, Feature 3	Label 9	Metric 1, Metric 2, Metric 3	Status 9	Version 9	Date 9	Author 9	License 9	Tags 9	Notes 9
Model 10	Dataset 10	100000	Regression	Source 10	Description 10	Feature 1, Feature 2, Feature 3	Label 10	Metric 1, Metric 2, Metric 3	Status 10	Version 10	Date 10	Author 10	License 10	Tags 10	Notes 10
Model 11	Dataset 11	110000	Classification	Source 11	Description 11	Feature 1, Feature 2, Feature 3	Label 11	Metric 1, Metric 2, Metric 3	Status 11	Version 11	Date 11	Author 11	License 11	Tags 11	Notes 11
Model 12	Dataset 12	120000	Regression	Source 12	Description 12	Feature 1, Feature 2, Feature 3	Label 12	Metric 1, Metric 2, Metric 3	Status 12	Version 12	Date 12	Author 12	License 12	Tags 12	Notes 12
Model 13	Dataset 13	130000	Classification	Source 13	Description 13	Feature 1, Feature 2, Feature 3	Label 13	Metric 1, Metric 2, Metric 3	Status 13	Version 13	Date 13	Author 13	License 13	Tags 13	Notes 13
Model 14	Dataset 14	140000	Regression	Source 14	Description 14	Feature 1, Feature 2, Feature 3	Label 14	Metric 1, Metric 2, Metric 3	Status 14	Version 14	Date 14	Author 14	License 14	Tags 14	Notes 14
Model 15	Dataset 15	150000	Classification	Source 15	Description 15	Feature 1, Feature 2, Feature 3	Label 15	Metric 1, Metric 2, Metric 3	Status 15	Version 15	Date 15	Author 15	License 15	Tags 15	Notes 15
Model 16	Dataset 16	160000	Regression	Source 16	Description 16	Feature 1, Feature 2, Feature 3	Label 16	Metric 1, Metric 2, Metric 3	Status 16	Version 16	Date 16	Author 16	License 16	Tags 16	Notes 16
Model 17	Dataset 17	170000	Classification	Source 17	Description 17	Feature 1, Feature 2, Feature 3	Label 17	Metric 1, Metric 2, Metric 3	Status 17	Version 17	Date 17	Author 17	License 17	Tags 17	Notes 17
Model 18	Dataset 18	180000	Regression	Source 18	Description 18	Feature 1, Feature 2, Feature 3	Label 18	Metric 1, Metric 2, Metric 3	Status 18	Version 18	Date 18	Author 18	License 18	Tags 18	Notes 18
Model 19	Dataset 19	190000	Classification	Source 19	Description 19	Feature 1, Feature 2, Feature 3	Label 19	Metric 1, Metric 2, Metric 3	Status 19	Version 19	Date 19	Author 19	License 19	Tags 19	Notes 19
Model 20	Dataset 20	200000	Regression	Source 20	Description 20	Feature 1, Feature 2, Feature 3	Label 20	Metric 1, Metric 2, Metric 3	Status 20	Version 20	Date 20	Author 20	License 20	Tags 20	Notes 20

Figura 2: Estatísticas descritivas geradas pelo nó Data Explorer do KNIME.

Anexo 3

JavaScript Table View

Show 10 entries Search:

☐	RowID	Consumptions	Count*(RowID)
☐	Row0	High Consumption	790
☐	Row1	Low Consumption	1998
☐	Row2	Medium Consumption	2090
☐	Row3	Medium-High Consumption	2180
☐	Row4	Medium-Low Consumption	1674

Showing 1 to 5 of 5 entries

Previous 1 Next

Figura 3: Distribuição de ocorrências por classe de consumo após normalização.

Anexo 4

Show 10 entries Search:

☐	RowID	Consumptions	Max*(Total (kWh))	Min*(Total (kWh))
☐	Row1	Low Consumption	1381979.4686903013	28038.275354206162
☐	Row3	Medium-High Consumption	1850911.7496696073	1426967.0594282192
☐	Row2	Medium Consumption	1879953.6023592553	1254132.6342526018
☐	Row4	Medium-Low Consumption	1903633.8961708276	1458665.8806654625
☐	Row0	High Consumption	2267476.4580009896	1125148.5863073987

Showing 1 to 5 of 5 entries

Previous 1 Next

Figura 4: Valores máximos e mínimos de consumo total para cada classe de classificação.

Anexo 5




Figura 5: Matriz de correlação linear entre as variáveis numéricas do dataset.

Anexo 6




Figura 6: Box plot da variável Total (kWh), evidenciando outliers nos valores baixos.

Anexo 7




Figura 7: Consumo horário médio por dia da semana.

Anexo 8




Figura 8: Mapa de calor do consumo médio total por mês e hora do dia.

Anexo 9



Figura 9: Consumo médio total por estação do ano.

Anexo 10



Figura 10: Consumo médio total por período do dia (Madrugada, Manhã, Tarde, Noite).

Anexo 11




Figura 11: Consumo médio por nível de tensão e classe de consumo.

Anexo 12




Figura 12: Distribuição das classes de consumo por mês.

Anexo 13

☐	RowID	Date/Time	Day	Month	ValidDate
☐	Row726	2025-11-32 16:00:00	32	11	No
☐	Row1158	2024-02-30 17:00:00	30	2	No
☐	Row1256	2024-02-30 07:00:00	30	2	No
☐	Row3284	2025-11-32 18:00:00	32	11	No
☐	Row4641	2026-13-04 07:00:00	4	13	No
☐	Row6703	2024-02-30 16:00:00	30	2	No
☐	Row6829	2025-11-32 16:00:00	32	11	No

Showing 1 to 7 of 7 entries

Previous1Next

Figura 13: Registos identificados com datas inválidas no dataset.

Anexo 14

☐	RowID ↕	precipitation (mm) ↕	rain (mm) ↕	compare_result ↕
☐	Row19	0.4	0.4	TRUE
☐	Row21	0.4	0.4	TRUE
☐	Row23	0.4	0.4	TRUE
☐	Row24	0.7	0.7	TRUE
☐	Row33	0.1	0.1	TRUE
☐	Row53	0.2	0.2	TRUE
☐	Row59	0.1	0.1	TRUE
☐	Row64	0.3	0.3	TRUE
☐	Row80	0.1	0.1	TRUE
☐	Row83	0.3	0.3	TRUE

Figura 14: Demonstração da igualdade entre as colunas precipitation e rain.

Anexo 15

JavaScript Table View

Show 10 entries Search:

☐	RowID ↕	Consistent sum ↕	Count*(RowID) ↕
☐	Row0	Match	8009
☐	Row1	Missing	723

Showing 1 to 2 of 2 entries Previous 1 Next

Figura 15: Verificação da consistência da soma das tensões parciais com o total.

Anexo 16

Show 10 entries Search:

☐	RowID ↕	Algorithm ↕	R ² Mean ↕
☐	Row0	Linear Regression	0.6435558144249367
☐	Row1	Decision Tree	0.6354944410805677
☐	Row2	GBT	0.8756944382489054

Showing 1 to 3 of 3 entries Previous 1 Next

Figura 16: Estatísticas dos modelos de regressão avaliados para imputação de valores ausentes.

Anexo 17

Regression Model Statistics					
Show 10 entries		Search:			
☐	RowID	Algorithm	R^2 Mean		
☐	Row0	Linear Regression	0.6435558144249367		
☐	Row1	Decision Tree	0.6354944410805677		
☐	Row2	GBT	0.8756944382489054		
Showing 1 to 3 of 3 entries				Previous	Next

Figura 17: Comparação detalhada dos modelos de regressão utilizados na imputação.

Anexo 18

☐	Algorithm	Overall Accuracy	Cohen's kappa	Overall Error	Execution Time
☐	Decision Tree	0.9264594389689158	0.908069592942092	0.07354056103108415	130
☐	Tree Ensemble	0.9528683345969169	0.9410813134088702	0.047131665403083146	126
☐	Logistic Regression	0.7993429365681072	0.7491359190242496	0.20065706343189285	131
☐	KNN	0.9566590851655294	0.9458203002094056	0.043340914834470556	125
☐	Naive Bayes	0.3690927470305787	0.21195313703446328	0.6309072529694213	132
☐	Random Forest	0.9532474096537781	0.9415556755151816	0.04675259034622189	130
☐	Fuzzy & Random Forest	0.7631769428176614	0.7040257645519945	0.23682305718233862	132
☐	H20	0.9533737680060652	0.9417137750776593	0.0466262319939348	133
☐	PNN	0.6580742987111448	0.5726581809260848	0.3419257012888552	124
☐	MLP	0.7652261814505938	0.7065018406045336	0.23477381854940613	93625
☐	Simple Regression Tree	0.8211484948140653	0.7764228183728944	0.17885150518593473	541
☐	Tree Ensemble (Regression)	0.8931008339651251	0.866345332230438	0.1068991660348749	540
☐	PMML Simple Regression Tree	0.9257855277567181	0.907227622482107	0.07421447224328195	542
☐	PMML Gradient Boosted Trees (Regression)	0.9179934293656811	0.8974863427852718	0.08200657063431893	542
☐	Regression	0.38156226223687545	0.22630776594443291	0.6184377377631245	537
☐	Random Forest Learner (Regression)	0.8981551680566086	0.8726621700351477	0.10184483194339146	529
☐	Keras	0.3857052498418722	0.23166113337442704	0.6142947501581277	1065766

Figura 18: Resultados dos 17 modelos utilizando Cross-Validation (10 folds).

Anexo 19

☐	Algorithm	Overall Accuracy	Cohen's kappa	Overall Error	Execution Time
☐	Decision Tree	0.9048421052631579	0.8810616985652506	0.09515789473684211	343
☐	Tree Ensemble	0.9469473684210526	0.9336839900852855	0.053052631578947365	307
☐	Logistic Regression	0.7941052631578948	0.7426375674361041	0.20589473684210527	316
☐	KNN	0.9301052631578948	0.9126325082857845	0.06989473684210526	341
☐	Naive Bayes	0.37642105263157893	0.22209815159086857	0.623578947368421	313
☐	Random Forest	0.9452631578947368	0.9315816765203825	0.05473684210526316	311
☐	Fuzzy & Random Forest	0.7993406593406593	0.7491873486552152	0.20065934065934066	345
☐	H2O	0.9452631578947368	0.9315772642828444	0.05473684210526316	340
☐	PNM	0.752421052631579	0.6906474517346892	0.24757894736842107	338
☐	MLP	0.783578947368421	0.7294644515292046	0.21642105263157896	110236
☐	Simple Regression Tree	0.8226621735467565	0.7783190241418256	0.17733782645324347	105
☐	Tree Ensemble (Regression)	0.8842105263157894	0.8551908576182191	0.11578947368421053	107
☐	PMML Simple Regression Tree	0.9177428411005053	0.8971658928767211	0.08225715889949467	101
☐	PMML Gradient Boosted Trees (Regression)	0.9128421052631579	0.8910525591485158	0.0871578947368421	107
☐	Regression	0.4573839662447257	0.3206220331185112	0.5426160337552742	105
☐	Random Forest Learner (Regression)	0.896	0.8699375123605093	0.104	100
☐	Keras	0.4252001685630004	0.2805953542789588	0.5747998314369995	86465

Figura 19: Resultados dos 17 modelos utilizando Hold-out Validation (80/20).

Anexo 20

Scorer View

Confusion Matrix

	High Consumpti...	Low Consumpti...	Medium Consu...	Medium-High Co...	Medium-Low Co...	
High Consumpti...	683	107	0	0	0	86.46%
Low Consumpti...	1	1997	0	0	0	99.95%
Medium Consu...	80	2010	0	0	0	0.00%
Medium-High Co...	1746	434	0	0	0	0.00%
Medium-Low Co...	1582	92	0	0	0	0.00%
	16.69%	43.04%	undefined	undefined	undefined	

Overall Statistics

Overall Accuracy	Overall Error	Cohen's kappa (κ)	Correctly Classified	Incorrectly Classified
30.69%	69.31%	0.171	2680	6052

Figura 20: Matriz de confusão e métricas do modelo de Clustering (k-Medoids, k=2).

Anexo 21

Scorer View

Confusion Matrix



	High Consumpti...	Low Consumpti...	Medium Consu...	Medium-High Co...	Medium-Low Co...	
High Consumpti...	683	107	0	0	0	86.46%
Low Consumpti...	1	1997	0	0	0	99.95%
Medium Consu...	80	2010	0	0	0	0.00%
Medium-High Co...	1746	434	0	0	0	0.00%
Medium-Low Co...	1582	92	0	0	0	0.00%
	16.69%	43.04%	undefined	undefined	undefined	

Overall Statistics

Overall Accuracy	Overall Error	Cohen's kappa (κ)	Correctly Classified	Incorrectly Classified
30.69%	69.31%	0.171	2680	6052

Figura 21: Tabela detalhada do scorer do clustering com métricas por classe.

Anexo 22

☐	RowID	Column Name	Column Type
☐	Date	Date	String
☐	Time	Time	String
☐	Global_active_power	Global_active_power	String
☐	Global_reactive_power	Global_reactive_power	String
☐	Voltage	Voltage	String
☐	Global_intensity	Global_intensity	String
☐	Sub_metering_1	Sub_metering_1	String
☐	Sub_metering_2	Sub_metering_2	String
☐	Sub_metering_3	Sub_metering_3	Number (Float)

Showing 1 to 9 of 9 entries

Previous 1 Next

Figura 1: Tipos de dados de cada coluna do dataset após conversão.

Anexo 23

☐	RowID	missingCount	Count(Date)
☐	Row0	0	20492
☐	Row1	7	260

Showing 1 to 2 of 2 entries

Previous 1 Next

Figura 2: Verificação de que todas as linhas com valores omissos estão completamente vazias.

Anexo 24

☐	RowID	ValidDate	Count*(Day)
☐	Row0	Yes	20752

Showing 1 to 1 of 1 entries

Previous 1 Next

Figura 3: Verificação do número de datas inválidas no dataset.

Anexo 25

☐	RowID	Column Name	Column Type	Column Index	Lower Bound	Upper Bound
☐	Hour	Hour	Number (Integer)	0	0	23
☐	Minute	Minute	Number (Integer)	1	0	59
☐	Second	Second	Number (Integer)	2	0	0

Showing 1 to 3 of 3 entries

Previous 1 Next

Figura 4: Pesquisa por valores de tempo inválidos no dataset.

Anexo 26

☐	RowID	isLawVerified	Count*(Time)
☐	Row0	false	4589
☐	Row1	true	16163

Showing 1 to 2 of 2 entries

Previous 1 Next

Figura 5: Verificação da Lei de Ohm — relação entre potência e intensidade para tensão constante ($\sim 235V$).

Anexo 27




Figura 6: Relação de proporcionalidade direta entre a intensidade da corrente e a potência ativa.

Anexo 28

☐	RowID	isLawVerified	Count(Time)
☐	Row0	false	272
☐	Row1	true	20480

Showing 1 to 2 of 2 entries

Previous 1 Next

Figura 7: Análise da conservação de energia e relação entre sub-medições e consumo total.

Anexo 29




Figura 8: Observação de que a corrente foi medida em incrementos de 0.2 A.

Anexo 30

		corr = -1	corr = +1	corr = n/a		RowID	Glob...	Volt...	Glob...	Sub...	Sub...	Sub...	Glob...	Glob...	Sub...	Mon...	Mon...	Day ...	Day ...	Hour	Year
RowID																					
Global_reactive_p...																					
Voltage																					
Global_intensity																					
Sub_metering_1																					
Sub_metering_2																					
Sub_metering_3																					
Global_active_pow...																					
Global_active_power																					
Sub_metering_other																					
Month (Name)																					
Month (Number)																					
Day of Week (Num...																					
Day of Week (Name)																					
Hour																					
Year																					

Figura 9: Matriz de correlação linear entre as variáveis numéricas do dataset.

Anexo 31




Figura 10: Potência ativa média por estação do ano.

Anexo 32




Figura 11: Potência ativa média por período do dia.

Anexo 33




Figura 12: Consumo horário por dia da semana.

Anexo 34




Figura 13: Consumo total médio por dia da semana para cada hora do dia.

Anexo 35




Figura 14: Consumo total médio por mês para cada hora do dia.

Anexo 36




Figura 15: Soma da potência consumida ao longo dos meses.

Anexo 37




Figura 16: Evolução da potência ao longo do ano de 2007.

Anexo 38




Figura 17: Proporção das sub-medições ao longo dos anos.

Anexo 39

☐	☐	Algorithm ☐	Overall Accuracy ☐	Cohen's kappa ☐	Overall Error ☐	Execution Time ☐
☐	☒	Decision Tree	0.9459722560233633	0.9324653200292041	0.05402774397663665	70
☐	☒	Tree Ensemble	0.9516670722803602	0.9395838403504503	0.04833292771963982	70
☐	☒	Logistic Regression	0.925675346799708	0.9070941834996349	0.07432465320029204	69
☐	☒	KNN	0.7066839714471123	0.6334637485529488	0.29331602855288774	68
☐	☒	Naive Bayes	0.7838403504502311	0.7298004380627889	0.2161596495497688	69
☐	☒	Random Forest	0.9522511559990265	0.9403139449987832	0.04774884400097347	67
☐	☒	Fuzzy & Random Forest	0.7596495497688002	0.6995619372110002	0.2403504502311998	68
☐	☒	H20	0.9470917498174738	0.9338646872718422	0.052908250182526165	71
☐	☒	PNN	0.20569481625699684	0.007118520321246075	0.7943051837430032	68
☐	☒	MLP	0.9091749817473838	0.8864687271842298	0.09082501825261621	210592

Figura 18: Resultados dos modelos de classificação com Cross-Validation.

Anexo 40

☐	☐	Algorithm ☐	Overall Accuracy ☐	Cohen's kappa ☐	Overall Error ☐	Execution Time ☐
☐	☒	Decision Tree	0.936404931862427	0.920504138457389	0.063595068137573	130
☐	☒	Tree Ensemble	0.9511680726800779	0.9389570648023765	0.04883192731992213	132
☐	☒	Logistic Regression	0.9219662556781311	0.9024555064556912	0.07803374432186892	132
☐	☒	KNN	0.7087929915639195	0.6360996963128667	0.2912070084360805	132
☐	☒	Naive Bayes	0.7498377676833226	0.6874413472913161	0.2501622323166775	132
☐	☒	Random Forest	0.9513303049967553	0.9391596170411767	0.04866969500324465	132
☐	☒	Fuzzy & Random Forest	0.8476638546398443	0.8097176112718789	0.15233614536015574	130
☐	☒	H20	0.9475989617131733	0.9344952652669798	0.05240103828682673	132
☐	☒	PNN	0.2091174561972745	0.00837545635287822	0.7908825438027255	132
☐	☒	MLP	0.9104477611940298	0.8880546897937907	0.08955223880597014	188756

Figura 19: Resultados dos modelos de classificação com Hold-out Validation (70/30).

Anexo 41

☐	☐	Algorithm ☐	R ² ☐	adjusted R ² ☐	mean absolute error ☐	mean absolute percentage error ☐	mean signed difference ☐	mean squared error ☐	root mean squared error ☐	Execution Time ☐
☐	☒	Simple Regression Tree	0.9655963389876243	0.9655963389876243	84.66881914855998	0.11295511601052376	-0.5536442047379085	38986.97252516464	197.45119023486447	84
☐	☒	Tree Ensemble (Regression)	0.9934680241825808	0.9934680241825808	37.5120553272121	0.05036186334303957	-1.8279064606840252	7402.778360204961	86.03940004558936	86
☐	☒	PMML Simple Regression Tree	0.8173277086764286	0.8173277086764286	248.74163668359103	0.3156130375988527	0.48425355019771277	207014.92361668363	454.98892691656096	84
☐	☒	PMML Gradient Boosted Trees (Regression)	0.9983991493805496	0.9983991493805496	20.99919859996017	0.03391627185327072	2.4883401030095986	1876.475761550065	43.318307464051095	88
☐	☒	Regression	0.9983991552033136	0.9983991552033136	26.42137584739061	0.0461247961118871	-0.0032769637382279613	1814.2463688884511	42.59397103920285	89
☐	☒	Random Forest Learner (Regression)	0.9934948407654666	0.9934948407654666	37.1810046006945	0.04811387818531343	-1.838405394312104	7372.195816123427	85.86149204459137	91
☐	☒	Keras	0.2948650926349617	0.2948650926349617	391.1125109620874	0.3705829730396046	-371.5103941728309	799133.3797820518	893.9426042996563	990387

Figura 20: Resultados dos modelos de regressão com Cross-Validation (com Global_intensity).

Anexo 42

☐	Algorithm	R ²	adjusted R ²	mean absolute error	mean absolute percentage error	mean signed difference
☐	Simple Regression Tree	0.97424882231508	0.97424882231508	82.10449196337841	0.11739185460458505	0.7433531546326222
☐	Tree Ensemble (Regression)	0.9929376986030841	0.9929376986030841	40.122001893290616	0.05122468957803715	-1.799157707471464
☐	PMML Simple Regression Tree	0.9976458445558367	0.9976458445558367	27.31853655821318	0.03853713818585836	-0.20344801628962206
☐	PMML Gradient Boosted Trees (Regression)	0.9987405406787354	0.9987405406787354	20.501707025894408	0.03403640179895667	2.0948284284081864
☐	Regression	0.9984445105949851	0.9984445105949851	26.539273909579148	0.046248338355296105	-0.5798360137881747
☐	Random Forest Learner (Regression)	0.9929389478758558	0.9929389478758558	40.23488013884324	0.051288448581999074	-1.7446643701153877
☐	Keras	0.9982138466390797	0.9982138466390797	30.610333073938815	0.04825677252088259	-14.107309511780338

Figura 21: Resultados dos modelos de regressão com Hold-out Validation (com Global_intensity).

Anexo 43

☐	Algorithm	R ²	adjusted R ²	mean absolute error	mean absolute percentage error	mean signed difference	mean squared error	root mean squared error	Execution Time
☐	Simple Regression Tree	0.6960026148142839	0.6960026148142839	328.91001997565473	0.4173445338357534	-4.633146492407855	344501.5005211039	586.9425018867724	47
☐	Tree Ensemble (Regression)	0.8471475221207054	0.8471475221207054	247.154601039995	0.33804540245145276	-3.5826318928631067	173230.28077330466	416.20941937119187	49
☐	PMML Simple Regression Tree	0.42606587121755424	0.42606587121755424	544.388341121978	0.8103287578094766	0.01617159689592316	650432.1679627821	806.4937494877329	48
☐	PMML Gradient Boosted Trees (Regression)	0.8427026329803922	0.8427026329803922	246.02957687501038	0.31480531460838757	-28.450609709235284	178257.47333001453	422.205487091315	53
☐	Regression	0.7556666403471275	0.7556666403471275	356.2676010868629	0.5626423047518008	0.020945246577790747	276895.9759263059	526.2090610454233	53
☐	Random Forest Learner (Regression)	0.8472447695738671	0.8472447695738671	247.24911379932388	0.3384313791274022	-3.43426269459958	173105.40652651875	416.0593786066104	50
☐	Keras	0.13528994601772526	0.13528994601772515	604.28807570087	0.6934875785496019	-357.2338104168823	980006.855031176	989.9529559687046	355521

Figura 22: Resultados dos modelos de regressão com Cross-Validation (sem Global_intensity).

Anexo 44

☐	Algorithm	R ²	adjusted R ²	mean absolute error	mean absolute percentage error	mean signed difference	mean squared error	root mean squared error	Execution Time
☐	Simple Regression Tree	0.6802500652549097	0.6802500652549097	338.34937965339407	0.44124590641487327	3.783364437421434	365312.5180687971	604.4108851342744	58
☐	Tree Ensemble (Regression)	0.8469475495774625	0.8469475495774625	253.02869066385824	0.3453241896796434	-3.3404666157383938	174865.68068323494	418.16944015941067	56
☐	PMML Simple Regression Tree	0.7084909726668838	0.7084909726668838	325.5955583731291	0.4127112947535029	0.45177545603158276	333060.47267339006	577.1139165480157	55
☐	PMML Gradient Boosted Trees (Regression)	0.8404243820810244	0.8404243820810244	250.21793166622604	0.31406483447988126	-29.584347408884476	182285.45393971837	426.9490062521734	62
☐	Regression	0.7561884416658196	0.7561884416658196	354.8884497970465	0.5496251973743902	-4.5331407274716335	278548.027929851	527.7764942945555	61
☐	Random Forest Learner (Regression)	0.8472446614159169	0.8472446614159169	252.7221390012307	0.34486645478827366	-3.362589285429106	174518.4801708178	417.75409054947363	60
☐	Keras	0.7471407422333076	0.7471407422333076	340.3470327138335	0.4703255975684653	-42.16085365807059	288883.5928775643	537.4789231937978	130943

Figura 23: Resultados dos modelos de regressão com Hold-out Validation (sem Global_intensity).

Anexo 45

Scorer View

Confusion Matrix

	High Consumption (Predicted)	Low Consumption (Predicted)	Medium Consumption (Predicted)	Medium-High Consumption ...	Medium-Low Consumption ...	
High Consumption (Actual)	2152	0	1957	0	0	52.37%
Low Consumption (Actual)	0	4099	0	0	0	100.00%
Medium Consumption (Actual)	0	3184	916	0	0	22.34%
Medium-High Consumption ...	0	0	4100	0	0	0.00%
Medium-Low Consumption ...	0	4084	0	0	0	0.00%
	100.00%	36.06%	13.14%	undefined	undefined	

Overall Statistics

Overall Accuracy	Overall Error	Cohen's kappa (κ)	Correctly Classified	Incorrectly Classified
34.97%	65.03%	0.187	7167	13325

Figura 24: Matriz de confusão e estatísticas globais do modelo de clustering (k-Medoids).